SGG综述中文阅读笔记

从基础概念到方法 评测与研究难点

场景图生成把图片中的对象及其关系组织成结构化表示。本笔记面向刚接触深度学习的读者，以“人骑马，马站在草地上”为共同例子，建立阅读综述和理解后续论文所需的基本框架。

对应论文：Guangming Zhu 等，Scene Graph Generation: A Comprehensive Survey，arXiv:2201.00443v2，2022年 6 月 22 日。该版本综述 138 篇代表性工作，主要从特征表示与特征优化组织方法。

1 基本概念

目标检测（Object Detection）回答对象在哪里、是什么。**场景图生成**（Scene Graph Generation，SGG）进一步预测对象之间如何联系。SGG 的输入是图像，输出是预测得到的对象及关系结构；人工标注为训练和评价提供参考答案。

概念	含义与例子
检测框 Bounding Box	用矩形区域定位对象，例如框住图片中的人或马。
对象类别 Object Class	说明区域中的对象是什么，例如“人”“马”。
特征向量 Feature Vector	模型从图像区域提取的一串数字，用于描述有助于识别和关系判断的信息。各维通常没有固定的人工语义。
关系三元组 Relationship Triplet	以〈主体，关系，客体〉表达联系，例如〈人，骑，马〉。



节点表示对象实例 箭头表示有方向的关系

场景图的节点对应具体对象实例。例如两个人应有两个节点，即使它们都属于“人”这一类别。箭头方向也有含义：〈人，骑，马〉与〈马，骑，人〉不同。

读图要点：检测框提供单个对象的位置；空间关系描述两个对象如何排列；动作关系还需要结合姿态等视觉证据。“人在马上方”是判断“骑”的线索，但不能单凭这一点确定关系。

原文定位：引言与第 2 节。图示和中文关系词为教学例子；实际类别与关系词表以具体数据集为准。

2 生成流程与数学符号

先把任务拆成三个相互依赖的部分：找到对象位置，判断对象类别，再预测对象间关系。收集预测的关系三元组后，可以组成场景图。

图片 → 检测框 B → 对象类别 O → 关系 R → 场景图 T

例如，模型先定位人和马，再识别两个区域的类别，最后结合区域特征、姿态、相对位置与上下文，判断两者是“骑”“牵着”还是其他关系。前两部分合起来对应目标检测。

符号怎样记

符号	本文中的含义	辅助记忆
S	输入的视觉场景，这里可理解为图片	Scene
B	对象候选检测框集合	Bounding boxes
O	公式中的对象类别信息	Objects
R	对象之间的关系集合	Relations
T	场景图	按作者定义理解，不强行展开英文词
p	概率	Probability
竖线 |	在已知右侧信息的条件下	条件概率记号

公式 2 的直观含义

略去原文下标，可将公式写成：

$$p(T \mid S) = p(B \mid S)\, p(O \mid B, S)\, p(R \mid O, B, S)$$

$p(B \mid S)$：看着图片，预测对象的位置。
$p(O \mid B, S)$：已知图片和位置，预测对象类别。
$p(R \mid O, B, S)$：已知图片、位置和类别，预测关系。

这是概率分解，用来表达各预测部分的条件依赖。三部分并非相互独立；具体模型也可以联合预测这些信息，而不必实现成三个独立运行的程序。

常见错误：如果把马识别为自行车，即使“骑”这个谓词没有变化，完整预测〈人，骑，自行车〉仍然是错的。对象类别错误可能影响后续关系判断，也会影响整个三元组是否正确。

原文定位：第 3 节开头，公式（2）。英文字母是作者定义的记号，跨论文阅读时应重新确认其含义。

3 模型使用哪些信息

上一节说明要预测什么；这一节关注模型凭哪些证据作判断。不同信息可以组合使用。

信息	在同一场景中的作用
外观 Appearance	观察人的姿态、马的形状以及人与马接触区域的视觉内容。
空间 Spatial	利用两个检测框的相对位置、大小和排列。
语义 Semantic	利用对象类别和关系名称的含义。
上下文 Context	结合周围对象和整体场景，例如马鞍等额外线索。

先验信息（Prior Information）包含统计先验和语言先验。前者来自训练数据中的出现频率；后者利用词语或类别之间的语义联系。**常识知识**（Commonsense Knowledge）提供对象属性、事件和交互的一般知识，可以来自训练数据，也可以来自外部知识库。

经验能够帮助判断，但“经常发生”并不等于“当前画面正在发生”。假设训练中“人骑马”很常见，模型也仍需根据当前图像区分骑马和牵马。

4 三种关系建模机制

消息传递 Message Passing

模型汇总其他对象或关系的信息，用于更新当前表示。例如，更新“人”的特征时，结合“马”和周围场景的特征。消息可以在三元组内部传递，也可以覆盖更广的上下文；实际传递的是数字特征。

注意力 Attention

模型为不同区域、特征或上下文分配不同权重。判断人是否骑马时，人与马的交互区域可能比远处草地更有帮助。注意力也可以用于消息传递，决定各部分信息的影响程度。

视觉平移嵌入 Visual Translation Embedding

嵌入把对象等信息映射为学习空间中的向量。VTransE 的直观约束是“主体表示加上关系向量，接近客体表示”。原文公式（9）写为：

$$W_s x_s + t_p \approx W_o x_o$$

x 表示输入特征，W 将特征映射到共同的关系空间，t 表示关系向量。相加的是映射后的数字表示；平移发生在学习到的特征空间。三种机制可以组合使用，并非固定的先后步骤。

原文定位：第 3.1.1 至 3.1.6 节。本轮先掌握机制的作用，不要求推导网络或损失函数。

5 任务设置与评价指标

数据集（Dataset）由图像及相应标注组成；人工参考答案称为真值（Ground Truth）。训练集用于学习，独立测试集用于评估。本文讨论 VRD、Visual Genome 等数据集。先确认任务设置，再比较分数。

任务	评测时已提供的信息	模型需要预测
PredCls 谓词分类	真值框 B 和真值类别 O	关系 R
SGCls 场景图分类	真值框 B	类别 O 和关系 R
SGGen 场景图生成	仅输入图像	框 B、类别 O 和关系 R

R@K 真实关系找回了多少

对一张图，取分数最高的 K 条关系预测，计算其中匹配到的真值关系数占该图真值关系总数的比例。K 指关系预测条数，不是对象数量。

$$R@K = \frac{\text{前 K 条预测中匹配到的真实关系数}}{\text{真实关系总数}}$$

例：真实关系有 5 条，模型前 10 条预测找回了其中 4 条，则 R@10 = 4/5 = 80%。分母是 5，不是 10。“前 10 条预测中有多大比例正确”对应精确率（Precision）的概念。

mR@K 对关系类别等权平均

按同一评测协议取得各谓词类别的召回率，再在纳入评估的类别间等权平均。它衡量平均召回，不是模型预测某种关系的概率，也不是为每类重新挑选 K 条预测。

假设仅评估两类关系	该类别的召回率
站在	90%
骑	10%

在这个简化例子中，mR@K = (90% + 10%)/2 = 50%。各类别在平均中占相同分量，因此这个指标更有助于观察低频类别被忽略的问题。

满召回不等于图完全正确。假设真值有 2 条，前 50 条预测包含全部真值，也可能含有许多错误预测，R@50 仍可达到 100%。错误预测虽然可能挤占前 K 名，召回率本身并不直接计算额外错误预测的比例。

比较实验需对齐数据集及划分、任务、K、匹配标准和图约束。匹配关系时还需按任务要求核对对象类别与定位；跨图及类别内如何汇总，以对应评测协议为准。原文定位：第 4、5 节。

6 研究难点与全文复述

难点	应怎样理解
有效关系稀疏	候选对象对多，有意义的关系少。需要筛选值得判断的对象对。
长尾分布	少数关系类别或三元组样本很多，许多其他类别样本很少。关注训练样本分布不均。
同类关系外观多样	例如人骑马与人骑自行车都包含“骑”，视觉外观与交互细节却不同。
关系定义和标注歧义	“马在草地上”和“马站在草地上”可能都合理；标注粒度和词语含义可能不一致。
评价不够全面	单个召回指标无法完整反映错误预测、描述细致程度和整体场景图质量。

区分两类数据问题：减少无关对象对，主要应对有效关系稀疏与计算成本；改善低频关系的训练，主要应对长尾分布。有效关系少，与关系类别本身“单一”，是不同概念。

视频与三维场景

视频 SGG需要描述关系随时间的变化，例如同一个人先牵马、后来骑马，并在不同帧中持续识别相同对象。**3D SGG**利用三维形状和位置；“前面、后面”等关系还需要明确参考方向。

从该版本的视角，研究机会包括更准确且细粒度的数据标注、按具体场景设计模型，以及发展统一有效的三维场景图表示。原文定位：第 3.2、3.3、6 节。

六句话复述整篇论文

1 SGG 从图像预测对象及其关系，并生成结构化的场景图。

2 基本流程是定位对象、判断类别、预测关系，并用三元组组织结果。

3 模型结合外观、空间、语义和上下文，也可以利用先验与常识。

4 消息传递、注意力和视觉平移嵌入用于改善表示或关系判断，并且可以组合。

5 主要困难包括关系稀疏、长尾分布、视觉差异、标注歧义和评测局限。

6 评估要区分任务条件，同时结合整体召回与类别平均召回理解模型表现。

回读路径：第 2 节定义 → 第 3 节流程与方法 → 第 5 节任务和指标 → 第 6 节挑战。沿“输入输出、方法作用、评测条件、剩余问题”四条线索做笔记。

复习检查

先独立作答，再核对答案要点。能解释理由，比只记住英文术语更重要。

1 SGG 的输入和输出分别是什么？请写出〈人，骑，马〉之外的一条关系。

2 B、O、R 分别回答什么问题？T 是否必须对应某个固定英文缩写？

3 人位于马的上方属于哪类信息？为什么还不能据此确定“骑”？

4 汇总周围对象的信息，并让其中一些信息占更大权重，结合了哪两种机制？

5 视觉平移发生在图片坐标中，还是学习到的特征空间中？

6 给出真值框和真值类别，只预测关系，属于哪种评测任务？

7 真值有 5 条，前 10 条预测找回 4 条，R@10 是多少？分母是什么？

8 mR@K 衡量关系预测概率吗？它如何对不同关系类别进行平均？

9 为什么 R@50 达到 100% 仍不能证明整个场景图完全正确？

10 A 多数对象对没有有意义关系；B 少数类别样本很多而多数类别很少。各是哪种难点？

答案要点

1 输入图像，输出预测的对象与关系结构；例如〈马，站在，草地〉。

2 B 定位，O 分类，R 描述联系；T 按作者定义表示场景图。

3 空间信息；还需结合外观、姿态、交互区域和上下文等证据。

4 消息传递和注意力。 5 学习到的特征空间。 6 PredCls。

7 4/5 = 80%，分母是真值关系总数。

8 衡量召回；先按协议计算类别召回率，再进行类别等权平均。

9 全部真值可以被找回，同时仍存在额外的错误预测。

10 A 是有效关系稀疏；B 是长尾分布。

来源与版本

Zhu G, Zhang L, Jiang Y, et al. Scene Graph Generation: A Comprehensive Survey. arXiv:2201.00443v2, 2022.

原文 https://arxiv.org/abs/2201.00443v2

Zotero 条目 6YMYISGT。学习示例中的数值用于说明计算；后续论文的具体标签、匹配和汇总规则，需查相应数据集与评测协议。